

2.3 多次元確率変数と

n変数への拡張.
(ベクトル)

同時確率分布と

周辺

行列の行列、

転置

多次元確率変数

n次元確率変数

$$\vec{X} = (X_1, X_2, \dots, X_n)$$

一次元 r.v. の組

$$= \begin{pmatrix} X_1 \\ X_2 \\ \vdots \\ X_n \end{pmatrix}$$

同時 p.d.

幾つかの r.v. を同時に扱うということ.

この多次元確率変数が従う確率分布と

同時確率分布

型
離散型と連続型


$$\begin{aligned} \text{p.d.f} \quad f(\vec{x}) &= P(\vec{X} = \vec{x}) \quad (\vec{x} = \vec{x}_1, \vec{x}_2, \dots) \\ &= 0 \quad (\vec{x} \neq \text{ " }) \end{aligned}$$

$$\begin{cases} f(\vec{x}_i) > 0 \\ \sum f(\vec{x}_i) = 1 \end{cases}$$

連續型分布

$$\begin{aligned}
 \text{p.d.f. (定義)} \quad P(\vec{X} \leq \vec{x}) &= P(X_1 \leq x_1, \dots, X_n \leq x_n) \\
 &= \int_{-\infty}^{x_1} \dots \int_{-\infty}^{x_n} f(t_1, \dots, t_n) dt_1 \dots dt_n \\
 &= \int_{-\infty}^{\vec{x}} f(\vec{t}) d\vec{t}
 \end{aligned}$$

$$\begin{cases} f(\vec{x}) = f(x_1, \dots, x_n) \geq 0 \\ \int_{-\infty}^{\vec{x}} f(\vec{x}) d\vec{x} = 1 \end{cases}$$



3種の赤玉 と 3種の白球
赤(1,2,3) (白1,2,3)

一次元
確率変数 $\begin{cases} X_1 = 1, 2 \text{ (赤)=1, 白=2)} \\ X_2 = 1, 2, 3 \text{ (数字=1, 2, 3)} \end{cases}$

二次元 r.v. $\vec{X} = (X_1, X_2)^t$

二次元 離散型 確率変数に対する 確率分布の例

	$X_2=1$	$X_2=2$	$X_2=3$	$P(X_1=x_i)$
$X_1=1$ (赤)	$2/10$	$1/10$	$1/10$	$4/10$
$X_1=2$ (白)	$1/10$	$1/10$	$4/10$	$6/10$
$P(X_2=x_2)$	$3/10$	$2/10$	$5/10$	1

周辺確率分布

\vec{X} の同時確率分布が決まっている時,

X_i だけの確率分布は?

例) 2.3.1 では,

- 取出した玉が赤である確率
- " 1 である確率

周辺確率分布と呼ぶ

多変数, 離散型の場合,

$\vec{X} = (X_1, \dots, X_m)$ の場合で,

$f(\vec{x}) = P(\vec{X} = \vec{x})$ が known

$$\begin{aligned}
 f_i(x_i) &= P(X_i = x_i) \\
 &= P\left(\bigcup_{x_2, \dots, x_m} \{(X_1, X_2, \dots, X_m) = (x_1, x_2, \dots, x_m)\}\right) \\
 &= \sum_{x_2, \dots, x_m} P((X_1, X_2, \dots, X_m) = (x_1, x_2, \dots, x_m)) \\
 &= \sum_{x_2, \dots, x_m} \underbrace{f(x_1, x_2, \dots, x_m)}_{\text{4ヶ所が2}}
 \end{aligned}$$

多変数, 連続型の場合

$$\begin{aligned}
 \int_{-\infty}^x \underbrace{f_1(x_1)}_{\substack{\text{周辺密度関数} \\ \text{周辺分布関数}}} dx_1 &= P(\underbrace{X_1}_{\substack{\text{周辺変数} \\ \text{周辺分布}}}_{\leq x}) \\
 &= P(\underbrace{X_1}_{\leq x}, -\infty < X_2 < \infty, \dots) \\
 &= \int_{-\infty}^x \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x_1, \dots, x_n) d\vec{x}
 \end{aligned}$$

周辺密度関数

$$\therefore \underline{f_1(x_1) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x_1, \dots, x_n) d\vec{x}^{(n)}}$$

2.4. 多次元確率変数の特性値 $\vec{X} = (X_1, \dots, X_n)$ の

期待値, 平均, 分散

期待値 (の定義) 一次元からの拡張 (段階的)

① $g(\vec{X}) = g_i(X_i)$ の時. (一変数のみ)

$$E[g(\vec{X})] = E[g_i(X_i)]$$

$$\begin{aligned} &= \int g(x_i) \cdot f(\vec{x}) d\vec{x} \\ &= \int g(x_i) f_i(x_i) dx_i \cdot \underbrace{\int f(\vec{x}) d\vec{x}}_{\substack{\text{他の変数} \\ \text{の積分}}} \end{aligned}$$

② $\vec{g}(\vec{X}) = (g_1(\vec{X}), \dots, g_n(\vec{X}))$ の時.

$$\vec{E}[g(\vec{X})] = (E[g_1(\vec{X})], \dots, E[g_n(\vec{X})])$$

$E[\]$ と $V[\]$ の返す型 (教科書に合せる)

$E[\alpha]$ • α が 1次元なら 1次元の平均値

• $\alpha = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix}$ なら $\begin{pmatrix} E[x_1] \\ \vdots \\ E[x_n] \end{pmatrix}$ n次元ベクトル

• $\alpha = \begin{pmatrix} a_{ij} \end{pmatrix}$ (3行3列) なら $\begin{pmatrix} \vdots \\ E[a_{ij}]_{ij} \\ \vdots \end{pmatrix}$ 3行3列

$V[\vec{x}]$ は共分散行列

\vec{X} の平均 (ベクトル) $\vec{\mu}$

$$\vec{\mu} \equiv (\mu_1, \dots, \mu_m)$$

$$\equiv \vec{E}[\vec{X}] \quad E: \text{ベクトルを返す関数}$$

$$= (E[X_1], \dots, E[X_m])$$

← 各々の E

一次元から n 次元への拡張の確認.

$$\int x_1 f(\vec{x}) d\vec{x} \stackrel{?}{=} \int x_1 f_1(x_1) dx_1$$

\uparrow \uparrow \uparrow \uparrow
 多次元 $E_{\vec{x}}[x_1]$ $\stackrel{?}{=} E_{x_1}[x_1]$ 一次元

$$E[x_1] = \int x_1 f(\vec{x}) d\vec{x}$$

$$\begin{aligned} g(\vec{x}) &= x_1 \\ &= \int x_1 \left(\int f(\vec{x}) d\vec{x}^{(1)} \right) \cdot dx_1 \\ &\quad \downarrow \\ &\quad f_1(x_1) \end{aligned}$$

$$= \int x_1 f_1(x_1) dx_1$$

\vec{X} の分散は?

2-4-3

「 X_i と X_j の間の関係」が生まれる

X_i の分散は(一次元と同様)

$$\sigma_i^2 \equiv V[X_i] = E[(X_i - \mu_i)^2] \quad i\text{-方向の}$$

X_i と X_j の共分散(covariance)

$i\text{-方向と}j\text{-方向の}$
関係

$$\begin{aligned}\sigma_{ij} &\equiv \text{Cov}[X_i, X_j] \\ &= E[(X_i - \mu_i)(X_j - \mu_j)] \quad ij\text{-内積}\end{aligned}$$



\vec{X} の共分散行列(covariance matrix)

$$\Sigma = V[\vec{X}] = \begin{pmatrix} \sigma_{11} & \cdots & \sigma_{1n} \\ \vdots & \ddots & \vdots \\ \sigma_{n1} & \cdots & \sigma_{nn} \end{pmatrix}$$

$$\sigma_{ii} = \sigma_i^2$$

分散

共分散の意味




降圧

$$x^2 + y^2 = a^2$$

$$a^2 x^2 + b^2 y^2 = c^2$$

$$a^2 (x-y)^2 + b^2 (x+y)^2 = c^2$$



任意ベクトル

行ベクトル

列ベクトル

$$\vec{a}' \Sigma \vec{a} = (a_1 \dots a_n) \begin{pmatrix} \text{---} \\ \Sigma \\ \text{---} \end{pmatrix} \begin{pmatrix} a_1 \\ \vdots \\ a_m \end{pmatrix}$$

二次形式

$$= (a_1 \dots a_m) \begin{pmatrix} \sum_{k=1}^m a_k \sigma_{1k} \\ \vdots \\ \sum_{k=1}^m a_k \sigma_{jk} \\ \vdots \\ \sum_{k=1}^m a_k \sigma_{mk} \end{pmatrix}$$

$$= \sum_{j=1}^m a_j \left(\sum_{k=1}^m a_k \sigma_{jk} \right)$$

$$= \sum_{j=1}^m \left(\sum_{k=1}^m a_j a_k \sigma_{jk} \right)$$

$$= \sum_{j=1}^m \sum_{k=1}^m a_j a_k E[(X_j - \mu_j)(X_k - \mu_k)]$$

$$= E \left[\sum_j \sum_k a_j a_k (X_j - \mu_j)(X_k - \mu_k) \right]$$

$$= E \left[\sum_j \sum_k \{a_j (X_j - \mu_j)\} \{a_k (X_k - \mu_k)\} \right]$$

$$= E \left[\left\{ \sum_i a_i (X_i - \mu_i) \right\}^2 \right] \geq 0$$

∴ 行列 Σ は 半正定値

二次形式 ≥ 0

≥ 0
(半)正定値行列 M

$$\vec{z}^t M \vec{z} \geq 0$$

$$\vec{z}^* M \vec{z} \geq 0$$

$\left\{ \begin{array}{l} \text{実対称行列} \\ \text{エルミート (複素)} \end{array} \right.$

全ての固有値 $\lambda \geq 0$

正定値なら

M は正則で, M^{-1} と ~~半~~正定値

正定値 なら $|M| > 0$

M が 対角化可能 (正定値) ならベクトルに対するグラム行列

$$M = P^{-1} D P$$

P は 2-ノルム行列

$$D = (d_{ij}) \quad d_{ij} = 0 \quad (i \neq j)$$

共分散行列 $\Sigma = V[\vec{X}]$ V は 行列を返す

前回の稱書
間違い、

$$= E[(\vec{X} - \vec{\mu}) \cdot (\vec{X} - \vec{\mu})^t]$$

↑ ↑
行列を返す 行列の積の意味

$$\vec{X} - \vec{\mu} = \begin{pmatrix} X_1 - \mu_1 \\ \vdots \\ X_n - \mu_n \end{pmatrix} \quad (\vec{X} - \vec{\mu})^t = (X_1 - \mu_1, \dots, X_n - \mu_n)$$

$$(\vec{X} - \vec{\mu}) \cdot (\vec{X} - \vec{\mu})^t = \begin{pmatrix} X_1 - \mu_1 \\ \vdots \\ X_n - \mu_n \end{pmatrix} \cdot (X_1 - \mu_1, \dots, X_n - \mu_n)$$

← 行列の乗算

$$= \begin{pmatrix} (X_1 - \mu_1)^2 & (X_1 - \mu_1)(X_2 - \mu_2) & \dots & (X_1 - \mu_1)(X_n - \mu_n) \\ (X_1 - \mu_1)(X_2 - \mu_2) & (X_2 - \mu_2)^2 & \dots & (X_2 - \mu_2)(X_n - \mu_n) \\ \vdots & \vdots & \ddots & \vdots \\ (X_n - \mu_n)(X_1 - \mu_1) & (X_n - \mu_n)(X_2 - \mu_2) & \dots & (X_n - \mu_n)^2 \end{pmatrix}$$

$$E[\quad] = \begin{pmatrix} \sigma_{11} & \sigma_{12} & \dots & \sigma_{1n} \\ \sigma_{21} & \sigma_{22} & \dots & \vdots \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{n1} & \dots & \dots & \sigma_{nn} \end{pmatrix}$$

相関係数 (correlation coefficient)

$$\rho_{ij} = \text{Corr}[X_i, X_j] = \frac{\text{Cov}[X_i, X_j]}{\sqrt{V[X_i] V[X_j]}}$$


標準化変数 z_i と z_j の共分散と等しい。

$$z_i = \frac{X_i - \mu_i}{\sigma_i}$$

$$X_i \in \{x_{i1}, \dots, x_{in}\}$$

$$X_j \in \{x_{j1}, \dots, x_{jn}\}$$

$$\mu_i = E[X_i] = \frac{1}{n} \sum_{k=1}^n x_{ik}$$



標本相関係数

二変数 $\{(x_i, y_i)\}$ ($i=1(n)$) が与えられた時,

$$\text{標本共分散 } S_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

〃 標準偏差 S_x, S_y

2.5 確率変数の独立性

例 コイン投げを k 回 行なう。

あべこが表である確率は $(\frac{1}{2}) \times (\frac{1}{2}) \times \dots (\frac{1}{2}) = (\frac{1}{2})^k$

一回毎に表である確率を k 回 かけ合わせる

ことで、確率が求められる。

一回の (ベルヌーイ試行) X , $X=0$, 表
 $X=1$ 裏

k 回の " X_1, X_2, \dots, X_k で表れる,

この時 $(X_1, \dots, X_k) = (x_1, \dots, x_k)$ とする確率は,

$$\begin{aligned} P((X_1, \dots, X_k) = (x_1, \dots, x_k)) \\ = P(X_1 = x_1) \cdot P(X_2 = x_2) \cdots P(X_k = x_k) \end{aligned}$$

連続型, 密度関数の表現では

$$f(x_1, \dots, x_k) = f_1(x_1) \cdots f_k(x_k)$$

$$\begin{aligned} F(x_1, \dots, x_k) &= P(X_1 \leq x_1, \dots, X_n \leq x_n) \\ &= F_1(x_1) \cdots F_n(x_n) \end{aligned}$$

独立

$$\begin{cases} f(\vec{x}) = \prod_i f_i(x_i) \\ F(\vec{x}) = \prod_i F_i(x_i) \end{cases}$$

X_1, \dots, X_n が独立で、 ← それぞれ独立な確率的変数
同一分布に従う

$$X_1, \dots, X_n \sim_{i.i.d} F(x)$$

変数変換
と独立性

X と Y が独立
↓

$g(X)$ と $h(Y)$ も独立.

独立性と
期待値

$$E[X_1 \cdots X_n] = E[X_1] \cdots E[X_n]$$

$$\left(E\left[\prod_i X_i\right] = \prod_i E[X_i] \right)$$

二変数の場合の確認

$$\begin{aligned} E[X_1 X_2] &= \iint x_1 x_2 f_1(x_1) f_2(x_2) dx_1 dx_2 \\ &= \int x_1 f_1(x_1) dx_1 \cdot \int x_2 f_2(x_2) dx_2 \\ &= E[X_1] \cdot E[X_2] \end{aligned}$$


独立性と
無相関性

X と Y が独立,

↓

X と Y は無相関

$$\begin{aligned}\therefore \text{Cov}[X, Y] &= E[(X - \mu_X)(Y - \mu_Y)] \\ &= E[X - \mu_X] \cdot E[Y - \mu_Y] \\ &= 0\end{aligned}$$




2.6 確率変数の和の平均と分散

$(\sum_{i=1}^n X_i)$ の平均と分散について考える

和の平均

$$\begin{aligned} E[X_1 + X_2] &= \int (x_1 + x_2) f(\vec{x}) d\vec{x} \\ &= \int x_1 f(\vec{x}) d\vec{x} + \int x_2 f(\vec{x}) d\vec{x} \\ &= E[X_1] + E[X_2] \end{aligned}$$



和の分散

$$\begin{aligned} V[X_1 + X_2] &= E[\{(X_1 + X_2) - (\mu_1 + \mu_2)\}^2] \\ &= E[\{(X_1 - \mu_1) + (X_2 - \mu_2)\}^2] \\ &= E[(X_1 - \mu_1)^2] + E[(X_2 - \mu_2)^2] \\ &\quad + 2E[(X_1 - \mu_1)(X_2 - \mu_2)] \\ &= V[X_1] + V[X_2] + 2\text{Cov}[X_1, X_2] \end{aligned}$$

(n)

一般化

$$E[\sum X_i] = \sum E[X_i]$$

$$V[\sum X_i] = \sum V[X_i] + 2 \underbrace{\sum_{i < j} \text{Cov}[X_i, X_j]}_{\text{無相関の時 } 0}$$

無相関の時 0

算術平均

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

" の
平均

$$E[\bar{X}] = E\left[\frac{1}{n} \sum X_i\right] = \frac{1}{n} \sum E[X_i] = \mu$$

" の
分散

$$\begin{aligned} V[X] &= V\left[\frac{1}{n} \sum X_i\right] \\ &= \frac{1}{n^2} V[\sum X_i] \\ &= \frac{1}{n^2} (n\sigma^2) \\ &= \frac{\sigma^2}{n} \end{aligned}$$

[A.2.2] 演習問題

(X_1, \dots, X_n) は連続型とし, X_i の
独立性を表わす2つの表現の同値性を示せ.

$$(1) f(x_1, \dots, x_n) = f_1(x_1) \cdots f_n(x_n)$$

$$(2) F(x_1, \dots, x_n) = F_1(x_1) \cdots F_n(x_n)$$

一般に $F(x) = \int_{-\infty}^x f(t) dt$

$$F'(x) = f(x)$$

$$\left(F(\vec{x}) = \prod \int_{-\infty}^{x_i} f_i(t_i) dt_i \right)$$

$$F(x_1, \dots, x_n) = \int_{-\infty}^{x_1} \cdots \int_{-\infty}^{x_n} f(x_1, \dots, x_n) d\vec{x}$$

$$dF(\vec{x}) = \sum \frac{\partial}{\partial x_i} F(\vec{x}) \cdot dx_i$$

$$\frac{dF_i(x_i)}{dx_i} \cdot dx_i$$

(1) \rightarrow (2)

$$\int \vec{f}(\vec{x}) d\vec{x} = \underbrace{\int f_1(x_1) dx_1} \cdot \underbrace{\dots} \cdot \underbrace{\int f_n(x_n) dx_n}$$

$$\int_{-\infty}^{x_i} f_i(x_i) dt_i = F_i(x_i) \therefore f_i(x_i) = \frac{\partial}{\partial x_i} F_i(x_i)$$

$$\therefore \frac{\partial}{\partial x_i} \int f(\vec{x}) d\vec{x} = f_i(x_i) \underbrace{\int \prod_j f_j(t_j) dt_j}_{1}$$

$$F(x_1, \dots, x_m) = \int_{-\infty}^{x_1} f_1(t_1) dt_1 \cdot \dots = \prod_i \int_{-\infty}^{x_i} f_i(t_i) dt_i$$

$$\frac{\partial}{\partial x_i} F(\vec{x}) = \prod_j \int_{-\infty}^{x_j} f_j(t_j) dt_j \cdot f_i(x_i)$$

変数変換
後の独立性

X と Y は独立,

$g(X), h(Y)$ は実数値連続関数

\Downarrow

$g(X)$ と $h(Y)$ も独立.


証明 (i)

$g(x) = x + a, h(y) = y + b$ の時.

$f(x, y) = f_1(x) \cdot f_2(y)$ が成り立っている

$f(x$

例2.5
(同じ)



16題

袋から取り出した玉が赤色であった時.



数字が3である 確率

モデル
確率空間
記述

玉の色を $X \in \{1=\text{赤}, 2=\text{白}\}$

玉の数字を $Y \in \{1, 2, 3\}$

確率モデル

16題の記述

$$P(Y=3 \mid X=1) = \frac{P(X=1, Y=3)}{P(X=1)}$$

事後 事前

$$= \frac{f(1, 3)}{f_X(1)} \leftarrow \text{同時}$$


周辺

条件付密度関数

$X=x$ のときに, $Y=y$ である条件付密度関数

$$f_{Y|X}(y|x) = \frac{f(x, y)}{f_X(x)} \quad \left(= f_y(y) \right)$$

? 独立なら



条件付期待値

$$E_{Y|X}[g(X, Y) | X=x] \\ = \int g(x, y) f_{Y|X}^Z(y|x) dy$$

$$E_X[E_{Y|X}[g(X, Y) | X=x]] \\ = \int \left(\int g(x, y) f_{Y|X}(y|x) dy \right) f_X(x) dx \\ = \iint g(x, y) \underline{f_{Y|X}(y|x) f_X(x)} dy dx \\ = \iint g(x, y) f_{X,Y}(x, y) dy dx \\ = E[g(X, Y)]$$


$$N = e^{-\frac{(x^2+y^2)}{2}} \cdot \frac{1}{\sqrt{2\pi}}$$

$$N(x,y) = e^{-\frac{(x-5)^2 + (y-3)^2}{2}} \cdot \frac{1}{\sqrt{2\pi}}$$

$$N(0,y), (x=0)$$

$$N(x,0) \& (y=0)$$

curve 3D



sage 2D 描画は？

父親の身長から、息子の身長を予測する (A25 演習問題)

model

父親の身長 X

息子の身長 Y

$g(X)$: Y を予測する関数

誤差

$E[\{Y - g(X)\}^2]$ 平均的誤差

最小誤差

誤差を最小にする $g(X)$ は?

条件付平均 $E_{Y|X}[Y | X]$ とする

$$(Y - g(X))^2 = Y^2 - 2Y \cdot g(X) + g^2(X)$$

$Y = g(X)$ ならば、最小

Y の分布と $g(X)$ の分布が
等しいならば

$$f_X(Y)$$

A.2.5の解

$$\text{ポイント} \quad E_{Y|X}[g(X)|x] \stackrel{x}{=} g(x)$$

$$E[h(x, Y)] = E_x[E_{Y|X}[h(x, Y)|x]]$$

$$\int \left[\int h(x, y) \frac{f(x, y)}{f_x(x)} dy \right] dx$$

$$f_x(x)$$

$$E[\{Y - g(X)\}^2]$$

$$= E[\{(Y - E_{Y|X}[Y|X]) + (E_{Y|X}[Y|X] - g(X))\}^2]$$

?

$$= E_x[E_{Y|X}[\{ \quad \quad \quad \}^2 | X]]$$

$$E_{Y|X} \left[\left\{ (Y - E_{Y|X}[Y|X]) + (E_{Y|X}[Y|X] - g(X)) \right\}^2 \right]$$

$$\{Y - g(X)\}^2 = \{ (Y - E_{Y|X}) + (E_{Y|X} - g(X)) \}^2$$

$$E_X \left[\{ (Y - E_{Y|X}) + (E_{Y|X} - g(X)) \}^2 \right] \rightarrow X \text{ 固定して}$$

$$= E_X \left[E_{Y|X} \left[\{ (Y - E_{Y|X}) + (E_{Y|X} - g(X)) \}^2 \mid X \right] \right]$$

$$= E_X$$

$$E_{Y|X} \left[(Y - E_{Y|X})(E_{Y|X} - g(X)) \mid X \right]$$

$$Y \cdot g(X) - Y E_{Y|X} + g(X) E_{Y|X} + (E_{Y|X})^2$$

2.8 確率とモーメントに関連した不等式

Chebyshev's

$$\mu = E[X], \sigma^2 = V[X] = E[X^2] - E[X]^2$$

$$P(|X - \mu| \geq \varepsilon) \leq \frac{\sigma^2}{\varepsilon^2}$$


証明

$$P(|X - \mu| \geq \varepsilon) = \int_{|x - \mu| \geq \varepsilon} f(x) dx$$

$$\leq \int_{|x - \mu| \geq \varepsilon} \left(\frac{|x - \mu|}{\varepsilon} \right)^2 f(x) dx$$

$$\leq \int_{-\infty}^{\infty} \frac{(x - \mu)^2}{\varepsilon^2} f(x) dx$$

$$= \frac{\sigma^2}{\varepsilon^2}$$



Chebyshev's


二つの点
はつりあう

$$\sigma^2 = \int_{-\infty}^{\infty} (x - \mu)^2 f(x) dx$$

$$\geq \int_{|x - \mu| \geq \varepsilon} (x - \mu)^2 f(x) dx$$

$$\geq \int_{|x - \mu| \geq \varepsilon} \varepsilon^2 f(x) dx$$

$$= \varepsilon^2 \int_{|x - \mu| \geq \varepsilon} f(x) dx = \varepsilon^2 P(|x - \mu| \geq \varepsilon)$$



平均 μ から ε 以上離れる確率は $\frac{\sigma^2}{\varepsilon^2}$

Cauchy-Schwarz's $(\sigma_{xy})^2 \leq \sigma_{xx} \cdot \sigma_{yy}$

X, Y : 確率変数 $(\sigma_x)^2$ $(\sigma_y)^2$
 σ_{xy}^2 σ_{xx} σ_{yy}

$$\text{Cov}[X, Y]^2 \leq V[X] \cdot V[Y]$$

分散

分散

$$E[(X - \mu_x)(Y - \mu_y)]^2 \leq E[(X - \mu_x)^2] \cdot E[(Y - \mu_y)^2]$$

証明

$$a = \sigma_{yy}, \quad b = -\sigma_{xy}, \quad Z = a(X - \mu_x) + b(Y - \mu_y)$$

この時、次式が成立する

$$\begin{aligned} 0 \leq E[Z^2] &= a^2(\sigma_x)^2 + b^2(\sigma_y)^2 + 2ab\sigma_{xy} \\ &= (\sigma_{yy})^2(\sigma_{xx}) + (\sigma_{xy})^2(\sigma_{yy}) + 2(\sigma_{yy})(\sigma_{xy})(\sigma_{xy}) \\ &= (\sigma_{yy})^2(\sigma_{xx} + \sigma_{xy}^2/\sigma_{yy}) = 2\sigma_{xy}\sigma_{yy} \\ &= \sigma_{yy}(\sigma_{xx}\sigma_{yy} - \sigma_{xy}^2) \end{aligned}$$

$$\sigma_{yy} > 0$$

$$\sigma_{yy} > 0 \rightarrow \sigma_{xx}\sigma_{yy} - \sigma_{xy}^2 \geq 0$$

$$\therefore V[X] \cdot V[Y] \geq \text{Cov}[X, Y]^2$$

$$\sigma_{yy} = 0$$

$$\sigma_{yy} = 0 \rightarrow Y = E[Y] \text{ 定数}$$

$$\sigma_{xy} = 0$$

Cauchy-Schwarz' の続き.

等号が成り立つ場合を考える.

$$Z = a(X - \mu_x) + b(Y - \mu_y)$$

$$E[Z^2] = a^2 \sigma_{xx} + b^2 \sigma_{yy} + 2ab \sigma_{xy}$$

$$\begin{aligned} a &= \sigma_{yy}, \quad b = -\sigma_{xy} \\ &= \sigma_{yy}^2 \sigma_{xx} + \sigma_{xy}^2 \sigma_{yy} - 2\sigma_{yy} \sigma_{xy}^2 \\ &= \sigma_{yy} (\sigma_{xx} \sigma_{yy} - \sigma_{xy}^2) \end{aligned}$$

∴ 等号が成り立つのは (確率 1 2) $E[Z^2] = 0$ かつ $Z = 0$

$$C = -a\mu_x - b\mu_y \text{ とおけば}$$

$$aX + bY + C = 0 \text{ が確率 1 2 成り立つ.}$$

$$\therefore a(X - \mu_x) + b(Y - \mu_y) = 0$$

$$\sigma_{yy}(X - \mu_x) - \sigma_{xy}(Y - \mu_y) = 0$$

直線の式.

Jensen's

X : 確率変数

$h(x)$: 連続, F =  x^2 とか $-\log(x)$

\Downarrow

$$E[h(X)] \geq h(E[X])$$

μ

証明

二回微分可能

$$h(x) \text{ が } F \text{ 凸} \Leftrightarrow h''(x) \geq 0$$


$$E[X] = \mu \text{ とおす, } h''(x) \geq 0$$



$$h(x) \geq h(\mu) + h'(\mu)(x - \mu)$$

$$E[h(X)] \geq h(E[X]) + h'(\mu) \underbrace{E[X - \mu]}_{=0}$$

$+ h''(\mu)(x - \mu)^2$
 ≥ 0

$$\therefore E[h(X)] \geq h(E[X])$$





2.9 確率 model

サイコロ投げに対する model

確率変数に
よる確率の
定ギmodel \wedge

$$\left(\begin{array}{l} \text{確率変数 } X \in \{1, \dots, 6\} \\ \text{確率分布 } P(X=k) = \frac{1}{6} \end{array} \right.$$

$$\text{標本空間 } \Omega = \{\omega_1, \omega_2, \dots, \omega_6\}$$

サイコロの目が x である標本 $\omega \in \omega_x$

シグマ集合体 (事象の集合)

$$\mathcal{A} = 2^\Omega$$

確率 model 上での確率をどう自然に誘導するか?

 x の目が出る事象

$$X(\omega_x) = x, \quad (x=1, 2, \dots, 6)$$

$$A_x = \{\omega_x\} = \{\omega \in \Omega : X(\omega) = x\}$$

— サイコロの目 x が出る事象。

$$P(A_x) = P(X=x) = \frac{1}{6} \quad (x=1 \sim 6)$$

偶数の目が出る事象

$$A_{2,4,6} = A_2 \cup A_4 \cup A_6$$

$$\begin{aligned} P(A_{2,4,6}) &= P(A_2 \cup A_4 \cup A_6) \\ &= P(A_2) + P(A_4) + P(A_6) \\ &= \frac{1}{6} + \frac{1}{6} + \frac{1}{6} \\ &= \frac{1}{2} \end{aligned}$$

全ての事象に対する確率を定める

全ての事象は 2^Ω の要素 e で, $e \subset \Omega$,
 $e_\alpha = \{\omega_i \mid i = \text{index}(e_\alpha)\}$
 \hookrightarrow この各 ω_i に対する $P(\omega_i)$ の和.

離散型 確率 model

確率変数 X が可算個の離散値ととり,
 X の値に対応する pdf が定まっている

連続型

(Ω, \mathcal{A}, P) が定まっているとする
 \mathcal{R} 区間

確率変数 X は, 実数で

$$X: \Omega \rightarrow \mathbb{R}$$

$$X^{-1}((-\infty, x]) = \{\omega: X(\omega) \leq x\} \in \mathcal{A} \quad (x \in \mathbb{R})$$

連続 確率モデル

$\Omega = \mathbb{R}$ 実数直線


\mathcal{B} = ボレル集合族

$p(x)$ は 積分可能な正値関数

$$\int_{-\infty}^{\infty} p(x) dx = 1$$

$A \in \mathcal{B}$ に対して

$$\mu(A) = \int_A p(x) dx$$



n次元拡張

$$\Omega = \mathbb{R}^n$$

\mathcal{B} = n次元のボレル集合族

$$p(\vec{x}) : \int_{\mathbb{R}^n} p(\vec{x}) d\vec{x} = 1$$

$$\mu(A) = \int_A p(\vec{x}) d\vec{x}$$